



(12) 发明专利申请

(10) 申请公布号 CN 114757860 A

(43) 申请公布日 2022. 07. 15

(21) 申请号 202210292231.9

(22) 申请日 2022.03.23

(71) 申请人 江西师范大学

地址 330022 江西省南昌市紫阳大道99号

(72) 发明人 江爱文 汪智峰

(74) 专利代理机构 北京中政联科专利代理事务

所(普通合伙) 11489

专利代理师 陈超

(51) Int. Cl.

G06T 5/50 (2006.01)

G06T 5/00 (2006.01)

G06N 20/00 (2019.01)

G06T 7/55 (2017.01)

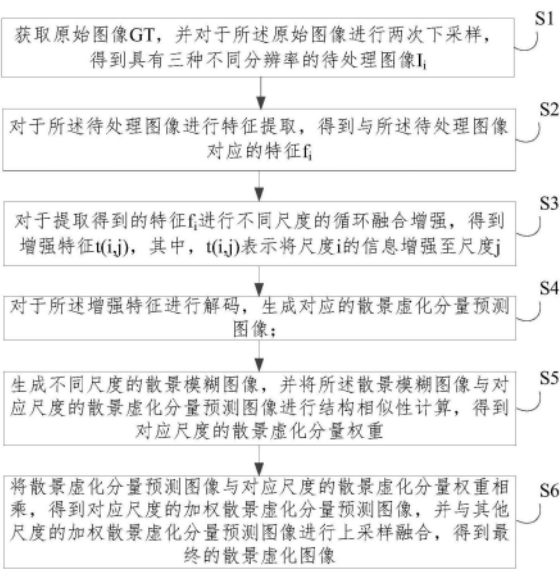
权利要求书2页 说明书7页 附图2页

(54) 发明名称

基于自监督多尺度金字塔融合网络的图像散景虚化方法

(57) 摘要

本发明实施例公开了一种基于自监督多尺度金字塔融合网络的图像散景虚化方法,该方法包括:获取原始图像,对于原始图像进行两次下采样,得到具有三种不同分辨率的待处理图像;对于待处理图像进行特征提取,得到与待处理图像对应的特征;对于提取得到的特征进行不同尺度的循环融合增强,得到增强特征;对于增强特征进行解码,生成对应的散景虚化分量预测图像;生成不同尺度的散景模糊图像,并将散景模糊图像与对应尺度的散景虚化分量预测图像进行结构相似性计算,得到对应尺度的散景虚化分量权重;将散景虚化分量预测图像与对应尺度的散景虚化分量权重相乘,得到对应尺度的加权散景虚化分量预测图像,对其进行上采样融合,得到最终的散景虚化图像。



1. 一种基于自监督多尺度金字塔融合网络的图像散景虚化方法, 其特征在于, 所述方法包括以下步骤:

步骤S1, 获取原始图像GT, 并对于所述原始图像进行两次下采样, 得到具有三种不同分辨率的待处理图像 $I_i$ ;

步骤S2, 对于所述待处理图像进行特征提取, 得到与所述待处理图像对应的特征 $f_i$ ;

步骤S3, 对于提取得到的特征 $f_i$ 进行不同尺度的循环融合增强, 得到增强特征 $t(i, j)$ , 其中,  $t(i, j)$ 表示将尺度i的信息增强至尺度j;

步骤S4, 对于所述增强特征进行解码, 生成对应的散景虚化分量预测图像 $\hat{I}_{i,j}$ ;

步骤S5, 生成不同尺度的散景模糊图像 $\hat{G}_i$ , 并将所述散景模糊图像与对应尺度的散景虚化分量预测图像进行结构相似性计算, 得到对应尺度的散景虚化分量权重;

步骤S6, 将散景虚化分量预测图像与对应尺度的散景虚化分量权重相乘, 得到对应尺度的加权散景虚化分量预测图像, 并与其他尺度的加权散景虚化分量预测图像进行上采样融合, 得到最终的散景虚化图像。

2. 根据权利要求1所述的方法, 其特征在于, 所述步骤S2中, 对于所述待处理图像进行特征提取的步骤, 包括:

利用特征提取模块 $FE_i$ 对于所述待处理图像分别进行特征提取, 其中, 特征提取模块 $FE_i$ 包括四个具有相似内部结构但参数不同的连续子块, 四个连续子块顺次连接。

3. 根据权利要求2所述的方法, 其特征在于, 所述连续子块包括三个顺次连接的残余卷积块, 其中, 第二个残余卷积块与第三个残余卷积块之间设置有线性整流模块, 第一个残余卷积块的输出与第三个残余卷积块的输出相加连接后作为所述连续子块的输出。

4. 根据权利要求1-3任一所述的方法, 其特征在于, 所述步骤S3中, 利用下式对于提取得到的特征 $f_i$ 进行不同尺度的循环融合增强, 得到增强特征 $t_{11}$ 、 $t_{21}$ 、 $t_{23}$ 、 $t_{33}$ , 其中,  $i=1, 2, 3$ :

$$\begin{aligned} t_{11} &= z_{21}; \\ t_{21} &= z_{21} \uparrow + f_2; z_{21} = f_2 \downarrow + f_1; \\ t_{23} &= z_{32}; z_{32} = f_3 \downarrow + f_2; \\ t_{33} &= f_3 + z_{32} \uparrow. \end{aligned}$$

5. 根据权利要求1所述的方法, 其特征在于, 所述步骤S4中, 对于所述增强特征进行解码的步骤, 包括:

利用解码器 $Gen(i, j)$ 对于所述增强特征进行解码, 其中, 解码器 $Gen(i, j)$ 包括四个具有相似内部结构但参数不同的连续子块, 四个连续子块顺次连接。

6. 根据权利要求5所述的方法, 其特征在于, 所述连续子块包括顺次连接的两个卷积块和一个反卷积块, 其中, 第一个卷积块与第二个卷积块之间设置有线性整流模块, 第一个卷积块的输入与第二个卷积块的输出相加连接后作为反卷积块的输入, 所述反卷积块的输出作为所述连续子块的输出。

7. 根据权利要求1-3、5、6任一所述的方法, 其特征在于, 所述步骤S5中, 生成不同尺度的散景模糊图像 $\hat{G}_i$ , 包括:

利用DefocusBlur算法生成不同尺度的散景模糊图像 $\hat{G}_i$ 。

8. 根据权利要求7所述的方法, 其特征在于, 所述步骤S5中, 将所述散景模糊图像与对应尺度的散景虚化分量预测图像进行结构相似性计算, 得到对应尺度的散景虚化分量权重, 包括:

在不同尺度上计算散景模糊图像 $\hat{G}_i$ 与对应尺度的散景虚化分量预测图像 $\hat{I}_{i,j}$ 的结构相似性:  $\alpha_{i,j} = \text{SSIM}(\hat{G}_i, \hat{I}_{i,j})$ ;

将 $\alpha_{i,j}$ 共同标准化到 $[0, 1]$ , 得到对应尺度的散景虚化分量权重 $w_{i,j}$ 。

9. 根据权利要求8所述的方法, 其特征在于, 所述散景虚化图像 $I_b$ 表示为:

$$I_b = P_2 \uparrow + w_{33} * \hat{I}_{33};$$

$$P_2 = P_1 \uparrow + w_{21} * \hat{I}_{21} + w_{23} * \hat{I}_{23};$$

$$P_1 = w_{11} * \hat{I}_{11}。$$

10. 根据权利要求1-3、5、6、8、9任一所述的方法, 其特征在于, 所述自监督多尺度金字塔融合网络的总损失函数表示为:

$$\text{Loss} = \text{Loss}_B + \text{Loss}_{\text{pyr}}$$

其中,  $\text{Loss}_B$ 表示全局损失函数,  $\text{Loss}_{\text{pyr}}$ 表示局部损失函数。

## 基于自监督多尺度金字塔融合网络的图像散景虚化方法

### 技术领域

[0001] 本发明属于图像处理领域,具体涉及一种基于自监督多尺度金字塔融合网络的图像散景虚化方法。

### 背景技术

[0002] 在实际应用中,通常可以通过专业的大口径、长焦距的单反相机拍摄具有散景虚化美感的图像,然而,对于具有紧凑光学元件和微型传感器的移动相机来说,通常是无法实现的。为了平衡照片质量的美学要求和昂贵的高端单反相机成本问题,散景虚化效果不得不通过模拟实现。因此,合成散景虚化渲染已经成为成像系统工程应用领域一个有吸引力的机器学习课题。

[0003] 近年来,合成散景虚化渲染的方法在很大程度上比较依赖场景深度信息。在这些基于深度信息的方法中,有一些是利用双像素自动对焦系统等硬件来估计场景深度,但这些专业硬件比较昂贵,难以广泛使用。此外,对于已经使用单目相机拍摄的图像,也缺乏准确的深度信息。

[0004] 在某种程度上,结合先验知识来模拟真实的散景虚化效果有可能提高图像的视觉效果,但基于先验知识的方法也存在一定的局限性:(1)与深度传感器相关的硬件并不总是可以在移动设备上使用;(2)通过软件对先验信息进行预处理通常比较耗费时间;(3)当估计的先验知识不起作用时,意外的失焦模糊反而会降低最终合成图像的质量。

[0005] 综上,亟需一种成本低、效果好、鲁棒性强的图像散景虚化方法。

### 发明内容

[0006] 本发明的目的是提供一种成本低、效果好、鲁棒性强的图像散景虚化方法,为此,本发明提供一种基于自监督多尺度金字塔融合网络的图像散景虚化方法。

[0007] 为了实现上述目的,本发明提出一种基于自监督多尺度金字塔融合网络的图像散景虚化方法,所述方法包括以下步骤:

[0008] 步骤S1,获取原始图像GT,并对于所述原始图像进行两次下采样,得到具有三种不同分辨率的待处理图像 $I_i$ ;

[0009] 步骤S2,对于所述待处理图像进行特征提取,得到与所述待处理图像对应的特征 $f_i$ ;

[0010] 步骤S3,对于提取得到的特征 $f_i$ 进行不同尺度的循环融合增强,得到增强特征 $t(i, j)$ ,其中, $t(i, j)$ 表示将尺度i的信息增强至尺度j;

[0011] 步骤S4,对于所述增强特征进行解码,生成对应的散景虚化分量预测图像 $\hat{I}_{i,j}$ ;

[0012] 步骤S5,生成不同尺度的散景模糊图像 $\hat{G}_i$ ,并将所述散景模糊图像与对应尺度的散景虚化分量预测图像进行结构相似性计算,得到对应尺度的散景虚化分量权重;

[0013] 步骤S6,将散景虚化分量预测图像与对应尺度的散景虚化分量权重相乘,得到对应尺度的加权散景虚化分量预测图像,并与其他尺度的加权散景虚化分量预测图像进行上

采样融合,得到最终的散景虚化图像。

[0014] 进一步地,所述步骤S2中,对于所述待处理图像进行特征提取的步骤,包括:

[0015] 利用特征提取模块 $FE_i$ 对于所述待处理图像分别进行特征提取,其中,特征提取模块 $FE_i$ 包括四个具有相似内部结构但参数不同的连续子块,四个连续子块顺次连接。

[0016] 进一步地,所述连续子块包括三个顺次连接的残余卷积块,其中,第二个残余卷积块与第三个残余卷积块之间设置有线性整流模块,第一个残余卷积块的输出与第三个残余卷积块的输出相加连接后作为所述连续子块的输出。

[0017] 进一步地,所述步骤S3中,利用下式对于提取得到的特征 $f_i$ 进行不同尺度的循环融合增强,得到增强特征 $t_{11}$ 、 $t_{21}$ 、 $t_{23}$ 、 $t_{33}$ ,其中, $i=1,2,3$ :

[0018]  $t_{11}=z_{21}$ ;

[0019]  $t_{21}=z_{21}\uparrow+f_2$ ;  $z_{21}=f_2\downarrow+f_1$ ;

[0020]  $t_{23}=z_{32}$ ;  $z_{32}=f_3\downarrow+f_2$ ;

[0021]  $t_{33}=f_3+z_{32}\uparrow$ 。

[0022] 进一步地,所述步骤S4中,对于所述增强特征进行解码的步骤,包括:

[0023] 利用解码器 $Gen(i,j)$ 对于所述增强特征进行解码,其中,解码器 $Gen(i,j)$ 包括四个具有相似内部结构但参数不同的连续子块,四个连续子块顺次连接。

[0024] 进一步地,所述连续子块包括顺次连接的两个卷积块和一个反卷积块,其中,第一个卷积块与第二个卷积块之间设置有线性整流模块,第一个卷积块的输入与第二个卷积块的输出相加连接后作为反卷积块的输入,所述反卷积块的输出作为所述连续子块的输出。

[0025] 进一步地,所述步骤S5中,生成不同尺度的散景模糊图像,包括:

[0026] 利用DefocusBlur算法生成不同尺度的散景模糊图像 $\hat{G}_i$ 。

[0027] 进一步地,所述步骤S5中,将所述散景模糊图像与对应尺度的散景虚化分量预测图像进行结构相似性计算,得到对应尺度的散景虚化分量权重,包括:

[0028] 在不同尺度上计算散景模糊图像 $\hat{G}_i$ ,与对应尺度的散景虚化分量预测图像 $\hat{I}_{i,j}$ 的结构相似性:  $\alpha_{i,j}=\text{SSIM}(\hat{G}_i, \hat{I}_{i,j})$ ;

[0029] 将 $\alpha_{i,j}$ 共同标准化到 $[0,1]$ ,得到对应尺度的散景虚化分量权重 $w_{i,j}$ 。

[0030] 进一步地,所述散景虚化图像 $I_b$ 表示为:

[0031]  $I_b = P_2\uparrow + w_{33} * \hat{I}_{33}$ ;

[0032]  $P_2 = P_1\uparrow + w_{21} * \hat{I}_{21} + w_{23} * \hat{I}_{23}$ ;

[0033]  $P_1 = w_{11} * \hat{I}_{11}$ 。

[0034] 进一步地,所述自监督多尺度金字塔融合网络的总损失函数表示为:

[0035]  $\text{Loss} = \text{Loss}_B + \text{Loss}_{\text{pyr}}$

[0036] 其中, $\text{Loss}_B$ 表示全局损失函数, $\text{Loss}_{\text{pyr}}$ 表示局部损失函数。

[0037] 本发明的有益效果为:本发明提出的基于自监督多尺度金字塔融合网络的图像散景虚化方法中,基于圆盘模糊卷积来模拟“弥散圆”现象的特定任务知识被用作网络训练的自监督信息,结构一致性被用来强调不同尺度散景虚化部分的重要性,因此,所述基于自监

督多尺度金字塔融合网络的图像散景虚化方法能够实现成本低、效果好、鲁棒性强的目的。

## 附图说明

[0038] 图1是根据本发明一实施例的一种基于自监督多尺度金字塔融合网络的图像散景虚化方法的流程图；

[0039] 图2是根据本发明一实施例的自监督多尺度金字塔融合网络的结构框图；

[0040] 图3是根据本发明一实施例的特征提取模块 $FE_i$ 及连续子块的结构框图；

[0041] 图4是根据本发明一实施例的解码器的结构框图。

## 具体实施方式

[0042] 为使本发明的目的、技术方案和优点更加清楚明了，下面结合具体实施方式并参照附图，对本发明进一步详细说明。应该理解，这些描述只是示例性的，而并非要限制本发明的范围。此外，在以下说明中，省略了对公知结构和技术的描述，以避免不必要地混淆本发明的概念。

[0043] 图1是根据本发明一实施例的一种基于自监督多尺度金字塔融合网络的图像散景虚化方法的流程图，图2是根据本发明一实施例的自监督多尺度金字塔融合网络的结构框图，所述自监督多尺度金字塔融合网络实现了三个金字塔层次上的多尺度信息融合，如图1和图2所示，所述基于自监督多尺度金字塔融合网络的图像散景虚化方法包括以下步骤：

[0044] 步骤S1，获取原始图像GT，并对于所述原始图像进行两次下采样，得到具有三种不同分辨率的待处理图像 $I_i$ ，其中， $i = \{1, 2, 3\}$ 为金字塔水平层级索引，从 $I_1$ 至 $I_3$ ，待处理图像的分辨率顺序升高；

[0045] 在本发明一实施例中，所述下采样的采样因子为2。

[0046] 步骤S2，对于所述待处理图像进行特征提取，得到与所述待处理图像对应的特征 $f_i$ ；

[0047] 在本发明一实施例中，利用编码器 $FE_i$ 作为特征提取模块对于所述待处理图像分别进行特征提取，得到与所述待处理图像对应的特征 $f_i$ ，如图2所示， $FE_1$ 为最低层金字塔对应的特征提取模块， $FE_2$ 为中层金字塔对应的特征提取模块， $FE_3$ 为最高层金字塔对应的特征提取模块。

[0048] 在本发明一实施例中，特征提取模块 $FE_i$ 包括四个具有相似内部结构但参数不同的连续子块。图3是根据本发明一实施例的特征提取模块 $FE_i$ 及连续子块的结构框图，如图3所示，四个连续子块顺次连接，即第一个连续子块Block1的输入为所述待处理图像 $I_i$ ，第一个连续子块的输出为第二个连续子块Block2的输入，第二个连续子块的输出为第三个连续子块Block3的输入，第三个连续子块的输出为第四个连续子块Block4的输入，第四个连续子块的输出即为对应特征提取模块 $FE_i$ 的输出，也即对于所述待处理图像 $I_i$ 进行特征提取得到的特征 $f_i$ 。

[0049] 如图3所示，所述连续子块包括三个顺次连接的残余卷积块，其中，第二个残余卷积块与第三个残余卷积块之间设置有线性整流模块，第一个残余卷积块的输出与第三个残余卷积块的输出相加连接后作为所述连续子块的输出，即，所述连续子块的计算公式可表达为：

[0050]  $X(\text{tmp}) = \text{Conv1}(X(\text{in}))$

[0051]  $X(\text{out}) = X(\text{tmp}) + \text{Conv3}(\text{ReLU}(\text{Conv2}(X(\text{tmp})))) \quad (1)$

[0052] 其中,  $X(\text{in})$  表示输入特征提取模块  $\text{FE}_i$  的数据,  $X(\text{tmp})$  表示  $X(\text{in})$  经过第一个残余卷积块  $\text{Conv1}$  后的输出,  $\text{Conv2}(X(\text{tmp}))$  表示  $X(\text{tmp})$  输入至第二个残余卷积块  $\text{Conv2}$  后的输出,  $\text{ReLU}(\text{Conv2}(X(\text{tmp})))$  表示第二个残余卷积块  $\text{Conv2}$  的输出经线性整流模块  $\text{ReLU}$  处理后得到的输出,  $\text{Conv3}(\text{ReLU}(\text{Conv2}(X(\text{tmp}))))$  表示线性整流函数  $\text{ReLU}$  的输出输入至第三个残余卷积块  $\text{Conv3}$  后的输出,  $X(\text{out})$  表示特征提取模块  $\text{FE}_i$  最终的输出。考虑到不同金字塔级别的特征提取流程相似, 因此, 为简单起见, 上式中省略了每个金字塔级别的索引  $i$ 。

[0053] 在本发明一实施例中, 不同连续子块的卷积参数如下表所示:

[0054]

	Block1	Block2	Block3	Block4
Conv1	S1_3_32	S2_32_64	S2_64_128	S2_128_256
Conv2	S1_32_32	S1_64_64	S1_128_128	S1_256_256
Conv3	S1_32_32	S1_64_64	S1_128_128	S1_256_256

[0055] 其中, 不同连续子块的所有卷积块均为  $3 \times 3$  大小的卷积核, 并且填充值为 1, 上表中 “Sk\_m\_n” 表示步长大小  $s=k$ , 输入通道大小为  $m$ , 输出通道大小为  $n$ 。

[0056] 步骤 S3, 对于提取得到的特征  $f_i$  进行不同尺度的循环融合增强, 得到增强特征  $t(i, j)$ , 其中,  $t(i, j)$  表示将尺度  $i$  的信息增强至尺度  $j$ ;

[0057] 为了达到最大限度地利用来自邻近尺度信息的目的, 该步骤在每个尺度水平上都各自进行了一次循环特征融合, 循环融合在相邻金字塔层之间起着信息利用和补充的作用。

[0058] 在该实施例中, 所述对于提取得到的特征  $f_i$  进行不同尺度的循环融合, 可得到  $t_{11}$ 、 $t_{21}$ 、 $t_{23}$ 、 $t_{33}$ , 计算过程可表示为:

$$\begin{aligned}
 & t_3 = f_3 + z_{32} \uparrow \\
 & z_{32} = f_3 \downarrow + f_2 \quad t_{23} = z_{32} \\
 & z_{21} = f_2 \downarrow + f_1 \quad t_{21} = z_{21} \uparrow + f_2 \\
 & t_1 = z_{21}
 \end{aligned} \quad (2)$$

[0059]

[0060] 其中,  $\downarrow$  表示下采样,  $\uparrow$  表示上采样;  $\text{FE}_3$  的输出  $f_3$  经过下采样后得到  $f_3 \downarrow$ , 与  $\text{FE}_2$  的输出  $f_2$  相加后得到来自邻近的更高分辨率尺度的向下信息融合  $z_{32} = f_3 \downarrow + f_2$ , 也可以认为是从邻近的更低分辨率尺度的向上信息融合  $t_{23}$ , 即  $t_{23} = z_{32}$ ;  $z_{32}$  经过上采样后得到  $z_{32} \uparrow$ , 与  $\text{FE}_3$  的输出  $f_3$  相加后得到  $t_{33}$ , 也可以简记为  $t_3$ , 即  $t_3 = f_3 + z_{32} \uparrow$ ;  $\text{FE}_2$  的输出  $f_2$  经过下采样后得到  $f_2 \downarrow$ , 与  $\text{FE}_1$  的输出  $f_1$  相加后得到来自邻近的更高分辨率尺度的向下信息融合  $z_{21} = f_2 \downarrow + f_1$ , 同时也作为  $t_{11}$ , 即  $t_1$  输出, 即  $t_1 = z_{21}$ ; 从邻近的更低分辨率尺度的向上信息融合  $t_{21}$  为  $z_{21}$  经过上采样后得到的  $z_{21} \uparrow$  与  $\text{FE}_2$  的输出  $f_2$  之和, 即  $t_{21} = z_{21} \uparrow + f_2$ 。

[0061] 上述循环操作可通过连续的向下和向上融合对子像素引入一些信息干扰, 有望提高网络模型在不同尺度上的鲁棒性。

[0062] 步骤 S4, 对于所述增强特征进行解码, 生成对应的散景虚化分量预测图像  $\hat{f}_{i,j}$ ;

[0063] 在本发明一实施例中, 利用解码器  $\text{Gen}(i, j)$  对于所述增强特征进行解码, 预测得

到对应的散景虚化分量预测图像 $\hat{I}_{i,j}$ 。图4是根据本发明一实施例的解码器的结构框图,所述解码器与特征提取模块具有相似的反向结构,如图4所示,所述解码器Gen(i,j)包括四个具有相似内部结构但参数不同的连续子块。四个连续子块顺次连接,即第一个连续子块Block1的输入为所述增强特征,第一个连续子块的输出为第二个连续子块Block2的输入,第二个连续子块的输出为第三个连续子块Block3的输入,第三个连续子块的输出为第四个连续子块Block4的输入,第四个连续子块的输出即为对应解码器Gen(i,j)的输出,也即预测得到的、与所述增强特征对应的散景虚化分量预测图像 $\hat{I}_{i,j}$ 。

[0064] 如图4所示,所述连续子块包括顺次连接的两个卷积块和一个反卷积块,其中,第一个卷积块与第二个卷积块之间设置有线性整流模块,第一个卷积块的输入与第二个卷积块的输出相加连接后作为反卷积块的输入,所述反卷积块的输出作为所述连续子块的输出,即所述连续子块的计算公式可表达为:

$$[0065] \quad Y(\text{tmp}) = Y_{\text{in}} + \text{Conv}_2(\text{ReLU}(\text{Conv}_1(Y_{\text{in}})))$$

$$[0066] \quad Y_{\text{out}} = \text{DeConv}_3(Y(\text{tmp})) \quad (3)$$

[0067] 其中, $Y_{\text{in}}$ 表示输入解码器Gen(i,j)的数据, $\text{Conv}_1(Y_{\text{in}})$ 表示 $Y_{\text{in}}$ 输入至第一个卷积块Conv1后的输出, $\text{ReLU}(\text{Conv}_1(Y_{\text{in}}))$ 表示第一个卷积块Conv1的输出经线性整流函数ReLU处理后得到的输出, $\text{Conv}_2(\text{ReLU}(\text{Conv}_1(Y_{\text{in}})))$ 表示线性整流函数ReLU的输出输入至第二个残余卷积块Conv2后的输出, $Y(\text{tmp})$ 表示 $Y_{\text{in}}$ 与第二个残余卷积块Conv2输出之和, $Y_{\text{out}}$ 表示 $Y(\text{tmp})$ 经过反卷积块DeConv<sub>3</sub>的输出,也即解码器Gen(i,j)最终的输出。考虑到不同金字塔级别的解码流程相似,因此,为简单起见,上式中省略了每个金字塔级别的索引i,j。

[0068] 在本发明一实施例中,不同连续子块的卷积参数如下表所示:

[0069]

	Block1	Block2	Block3	Block4
Conv1	S1_256_256	S1_128_128	S1_64_64	S1_32_32
Conv2	S1_256_256	S1_128_128	S1_64_64	S1_32_32
DeConv3	S2_256_128	S2_128_64	S2_64_32	S2_32_3

[0070] 其中,不同连续子块的所有卷积块均为3\*3大小的卷积核,并且填充值为1,所有的反卷积块均为4\*4大小的卷积核,并且填充值为1。上表中“Sk\_m\_n”表示步长大小s=k,输入通道大小为m,输出通道大小为n。

[0071] 步骤S5,生成不同尺度的散景模糊图像 $\hat{G}_i$ ,并将所述散景模糊图像与对应尺度的散景虚化分量预测图像进行结构相似性计算,得到对应尺度的散景虚化分量权重;

[0072] 在本发明一实施例中,可利用DefocusBlur算法生成不同尺度的散景模糊图像 $\hat{G}_i$ ,为增强网络提供自监督信息,模拟具有不同模糊程度和不同分辨率的景深图像,从而有效地提高了训练的效率和准确性。由于不同尺度的散景模糊,其半径变化是由磁盘模糊半径所决定。因此,在不同的金字塔尺度分支上需使用不同大小的模糊核,即 $\hat{G}_i = \text{DefocusBlur}(I_i, k_i)$ ,其中, $k_i = \{7, 5, 3\}$ 分别表示相应尺度上散景模糊核的大小。

[0073] 在本发明一实施例中,在不同尺度上计算提供自监督信息的散景模糊图像 $\hat{G}_i$ 与对应尺度的预测生成的散景虚化分量预测图像 $\hat{I}_{i,j}$ 的结构相似性: $\alpha_{i,j} = \text{SSIM}(\hat{G}_i, \hat{I}_{i,j})$ ,为了强



调各个分量的重要性,可将 $\alpha_{i,j}$ 共同标准化到 $[0,1]$ ,得到对应尺度的散景虚化分量权重 $w_{i,j}$ :

$$[0074] \quad w_{i,j} = \frac{\alpha_{i,j}}{\sum_i \alpha_{i,j}} \quad (4)$$

[0075] 步骤S6,将散景虚化分量预测图像 $\hat{I}_{i,j}$ 与对应尺度的散景虚化分量权重相乘,得到对应尺度的加权散景虚化分量预测图像,并与其他尺度的加权散景虚化分量预测图像进行上采样融合,得到最终的散景虚化图像。

[0076] 其中,散景虚化分量预测图像 $\hat{I}_{11}$ 与对应尺度的散景虚化分量权重 $w_{11}$ 相乘得到对应尺度的加权散景虚化分量预测图像,也即中间特征图 $P_1$ ,即 $P_1 = w_{11} * \hat{I}_{11}$ ;散景虚化分量预测图像 $\hat{I}_{21}$ 与对应尺度的散景虚化分量权重 $w_{21}$ 相乘得到对应尺度的加权散景虚化分量预测图像 $w_{21} * \hat{I}_{21}$ ,散景虚化分量预测图像 $\hat{I}_{23}$ 与对应尺度的散景虚化分量权重 $w_{23}$ 相乘得到对应尺度的加权散景虚化分量预测图像 $w_{23} * \hat{I}_{23}$ ,加权散景虚化分量预测图像 $P_1$ 的上采样与加权散景虚化分量预测图像 $w_{21} * \hat{I}_{21}$ 、加权散景虚化分量预测图像 $w_{23} * \hat{I}_{23}$ 之和表示为中间特征图 $P_2$ ,即 $P_2 = P_1 \uparrow + w_{21} * \hat{I}_{21} + w_{23} * \hat{I}_{23}$ ;  $P_2$ 的上采样与加权散景虚化分量预测图像 $w_{33} * \hat{I}_{33}$ 之和即为最终的散景虚化图像 $I_b = P_2 \uparrow + w_{33} * \hat{I}_{33}$ ,其中,所述权重能够自适应地控制融合过程中各自尺度信息的重要性。

[0077] 另外,对于所述自监督多尺度金字塔融合网络的全面的超参数学习,本发明考虑了全局和分量层面的训练损失。即,所述自监督多尺度金字塔融合网络的总损失函数可表示为:

$$[0078] \quad \text{Loss} = \text{Loss}_B + \text{Loss}_{\text{pyr}}$$

[0079] 其中, $\text{Loss}_B$ 表示全局损失函数, $\text{Loss}_{\text{pyr}}$ 表示局部损失函数。

[0080] 所述全局损失函数 $\text{Loss}_B$ 可表示为:

$$[0081] \quad \text{Loss}_B = \|I_b - GT\|_1$$

[0082] 其中, $GT$ 表示原始图像, $I_b$ 表示所述原始图像对应的散景虚化图像, $\|\cdot\|_1$ 表示L1损失函数,L1损失函数有助于合成散景虚化图像的像素级重建。

[0083] 所述局部损失函数 $\text{Loss}_{\text{pyr}}$ 可表示为:

$$[0084] \quad \begin{aligned} \text{loss}_3 &= \left| \hat{I}_{33} - \hat{G}_3 \right|_1 + 0.1 * (1 - \text{SSIM}(\hat{I}_{33}, \hat{G}_3)) \\ \text{loss}_{23} &= \left| \hat{I}_{23} - \hat{G}_2 \right|_1 + 0.1 * (1 - \text{SSIM}(\hat{I}_{23}, \hat{G}_2)) \\ \text{loss}_{21} &= \left| \hat{I}_{21} - \hat{G}_2 \right|_1 + 0.1 * (1 - \text{SSIM}(\hat{I}_{21}, \hat{G}_2)) \\ \text{loss}_1 &= \left| \hat{I}_{11} - \hat{G}_1 \right|_1 + 0.1 * (1 - \text{SSIM}(\hat{I}_{11}, \hat{G}_1)) \\ \text{Loss}_{\text{pyr}} &= w_{33} * \text{loss}_3 + w_{23} * \text{loss}_{23} + w_{21} * \text{loss}_{21} + w_{11} * \text{loss}_1 \end{aligned}$$

[0085] 应当理解的是,本发明的上述具体实施方式仅仅用于示例性说明或解释本发明的

原理,而不构成对本发明的限制。因此,在不偏离本发明的精神和范围的情况下所做的任何修改、等同替换、改进等,均应包含在本发明的保护范围之内。此外,本发明所附权利要求旨在涵盖落入所附权利要求范围和边界、或者这种范围和边界的等同形式内的全部变化和修改例。

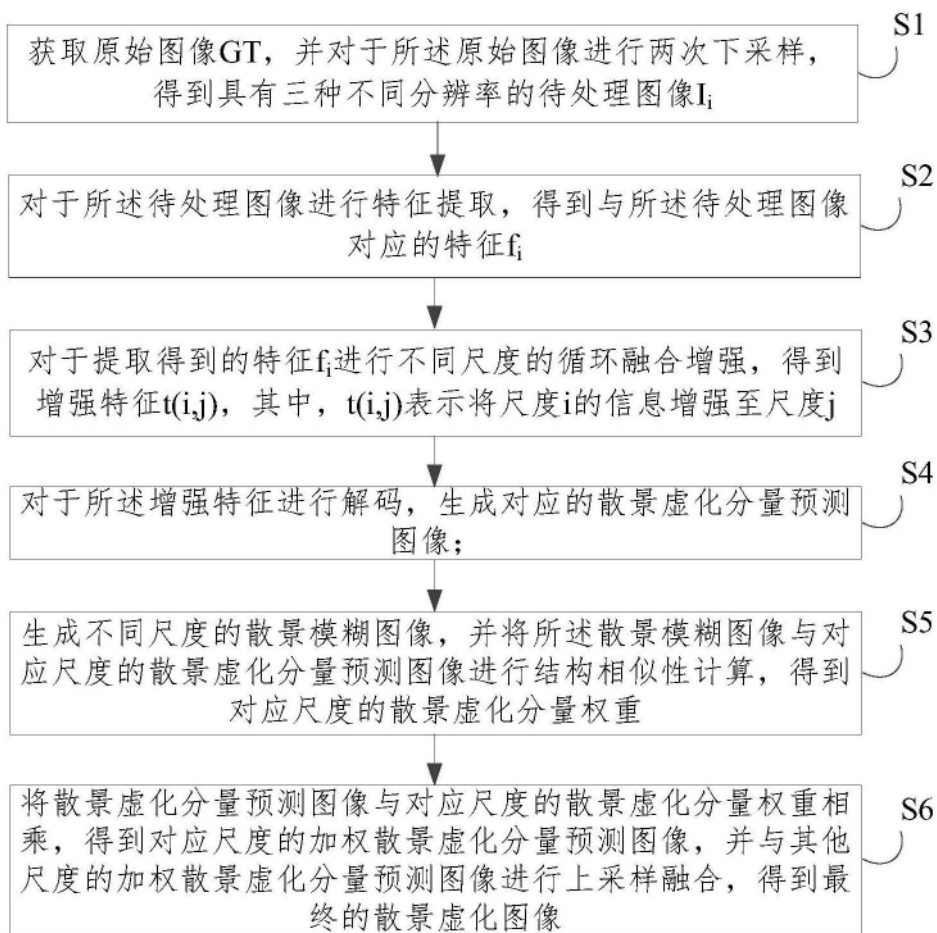


图1

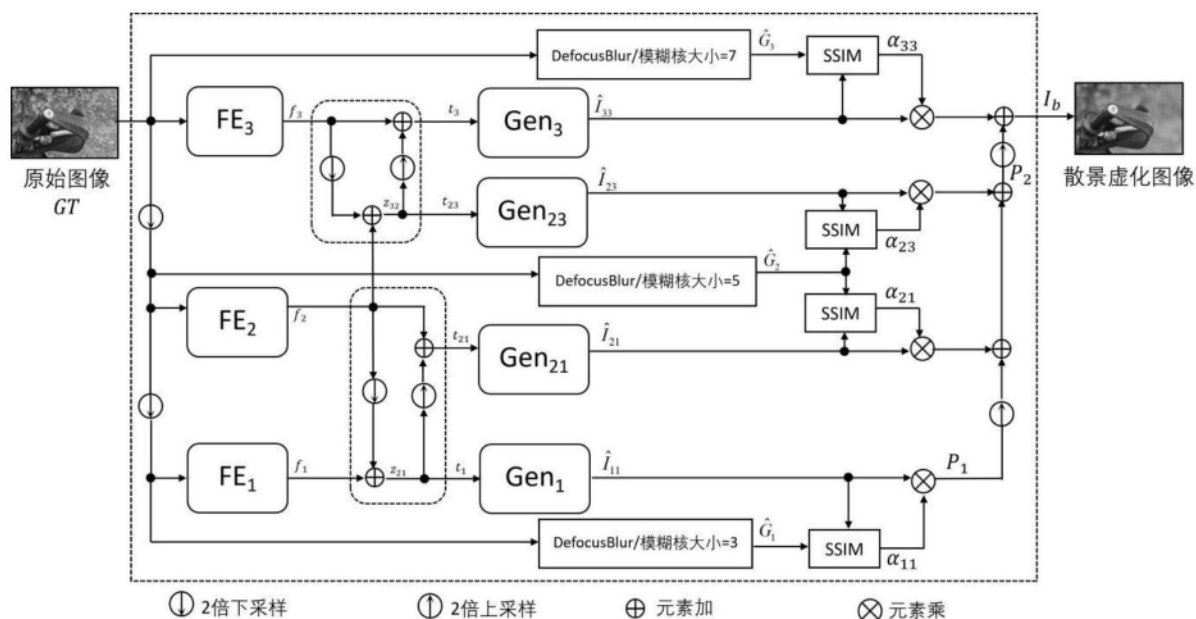


图2




图3

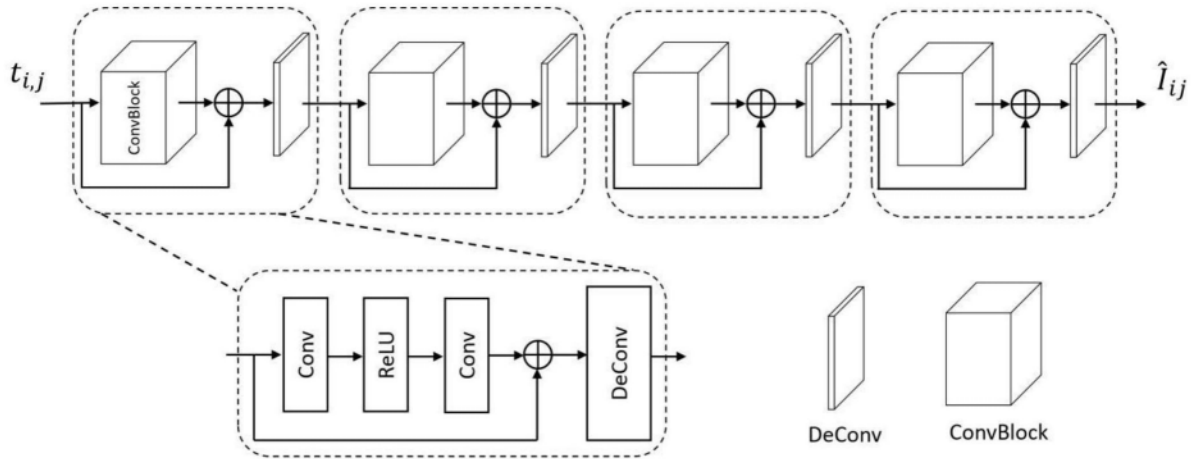


图4